

RELATÓRIO DE PROGRESSO – TRATAMENTO E ANÁLISE DE DADOS NA ÁREA DA SAÚDE

Aluno: Jorge Dias

Curso: Engenharia de Computação – UCAM

Disciplina/Projeto: Ciência de Dados Aplicada à Saúde

Ferramenta Utilizada: Google Colab (Python)

Data: Junho de 2026

1. Introdução

A qualidade dos dados é um dos fatores mais importantes para o sucesso de projetos de Ciência de Dados. Bases de dados reais frequentemente apresentam inconsistências, valores ausentes, erros de formatação e registros incompletos, tornando necessária a aplicação de técnicas de limpeza e preparação dos dados antes de qualquer análise.

O presente trabalho teve como objetivo realizar o tratamento e a análise exploratória de uma base de dados fictícia da área da saúde contendo informações de pacientes, incluindo dados demográficos, antropométricos e indicadores clínicos.

2. Objetivos

Objetivo Geral

Aplicar técnicas de limpeza, transformação e análise exploratória de dados utilizando Python no ambiente Google Colab.

Objetivos Específicos

- Identificar inconsistências na base de dados;
- Tratar valores ausentes;
- Padronizar formatos de dados;
- Validar cálculos existentes;
- Produzir análises estatísticas descritivas;
- Investigar relações entre variáveis clínicas;
- Gerar visualizações para apoio à interpretação dos resultados.

3. Caracterização da Base de Dados

A base utilizada contém inicialmente 1.500 registros e 13 variáveis relacionadas à saúde dos pacientes.

As principais variáveis presentes são:

- Identificação do paciente;
- Nome;

- Idade;
- Sexo;
- Cidade;
- Estado;
- Peso;
- Altura;
- IMC;
- Pressão arterial;
- Glicemia;
- Colesterol;
- Diagnóstico.

Durante a inspeção inicial foram identificadas inconsistências e valores ausentes em diversas colunas.

4. Diagnóstico Inicial dos Dados

A análise inicial permitiu identificar os seguintes problemas:

Variável	Valores Ausentes
Idade	36
Pressão Arterial	291
Glicemia	737
Colesterol	708
Diagnóstico	244

Também foram encontrados:

- Diferentes formas de representação do sexo (M, m, F, f, Masculino e Feminino);
- Valores de peso utilizando vírgula como separador decimal;
- Inconsistências de capitalização em nomes e cidades;
- Registros com idade igual a zero;
- Campos de diagnóstico em branco.

Foi realizada ainda uma verificação de duplicidade, não sendo encontrados registros duplicados na base.

5. Processo de Tratamento dos Dados

5.1 Criação de Ambiente de Trabalho Seguro

Inicialmente foi criada uma cópia da base original para preservar os dados brutos e permitir comparações entre as versões tratadas e não tratadas.

5.2 Padronização da Variável Sexo

Os valores foram normalizados para duas categorias únicas:

- Masculino
- Feminino

Esta etapa eliminou inconsistências causadas por diferenças de escrita.

5.3 Padronização da Pressão Arterial

Os diferentes formatos de representação foram convertidos para um padrão único utilizando o caractere "x" como separador.

Exemplo:

- 120/80 → 120x80

5.4 Padronização Textual

Foram aplicadas técnicas de normalização de texto:

- Nomes convertidos para formato Title Case;
- Cidades convertidas para formato Title Case;
- Estados convertidos para letras maiúsculas.

5.5 Conversão de Tipos de Dados

As colunas de peso e altura foram convertidas para formato numérico após a substituição de vírgulas por pontos decimais.

Esta etapa garantiu compatibilidade com operações matemáticas posteriores.

5.6 Validação do Índice de Massa Corporal (IMC)

Foi criada uma nova variável denominada "imc_calculado", utilizando a fórmula:

$$\text{IMC} = \text{Peso} / \text{Altura}^2$$

O resultado foi comparado com o IMC já existente na base, confirmando a consistência dos valores armazenados.

6. Tratamento de Valores Ausentes

6.1 Exclusão de Registros com Idade Ausente

Foram removidos 36 registros sem informação de idade.

6.2 Exclusão de Registros com Idade Igual a Zero

Foram identificados e removidos 9 registros contendo idade igual a zero, considerados inconsistentes para a análise proposta.

Ao final desta etapa, a base passou de:

- 1.500 registros iniciais
- para 1.455 registros válidos

Representando uma redução aproximada de apenas 3% da base original.

6.3 Preenchimento de Diagnósticos Ausentes

Os diagnósticos ausentes foram preenchidos com base na classificação do IMC calculado.

Foram utilizadas as seguintes categorias:

Faixa de IMC	Diagnóstico
Menor que 18,5	Baixo Peso
18,5 a 24,9	Saudável
25 a 29,9	Sobrepeso
30 ou mais	Obesidade

Após este procedimento, a coluna diagnóstico passou a não apresentar valores nulos.

7. Análise Exploratória dos Dados

7.1 Correlação entre IMC e Glicemia

Foi calculado o coeficiente de correlação de Pearson entre IMC e glicemia.

Resultado:

Correlação = -0,04

Este valor indica ausência de relação linear significativa entre as duas variáveis.

7.2 Correlação entre IMC e Colesterol

Foi calculado o coeficiente de correlação de Pearson entre IMC e colesterol.

Resultado:

Correlação = -0,02

Novamente observou-se uma correlação extremamente fraca.

7.3 Heatmap de Correlação

Foi produzida uma matriz de correlação para todas as variáveis numéricas da base, permitindo visualizar possíveis relações entre os indicadores clínicos.

7.4 Criação de Faixas Etárias

Os pacientes foram agrupados nas seguintes categorias:

- Criança
- Adolescente
- Adulto Jovem
- Adulto
- Idoso

Distribuição encontrada:

- Crianças: 152
- Adolescentes: 105
- Adultos Jovens: 281
- Adultos: 375
- Idosos: 531

Observou-se predominância de pacientes classificados como idosos.

7.5 Análises Comparativas

Foram produzidos gráficos para análise de:

- Glicemia média por faixa etária e sexo;
- Colesterol médio por faixa etária e sexo;
- Distribuição dos diagnósticos por faixa etária;
- Distribuição dos diagnósticos por sexo.

Essas análises permitiram identificar padrões populacionais e comparar indicadores clínicos entre diferentes grupos.

8. Tecnologias Utilizadas

Durante o desenvolvimento foram utilizadas as seguintes bibliotecas:

- Pandas
- NumPy
- Matplotlib
- Seaborn

Além do ambiente Google Colab para execução dos códigos.

9. Conclusão

Os resultados obtidos demonstram a importância das etapas de preparação e limpeza dos dados antes da realização de análises estatísticas.

O processo desenvolvido permitiu corrigir inconsistências, eliminar registros inválidos, padronizar informações e enriquecer a base com novas variáveis derivadas.

As análises exploratórias mostraram que não há correlação significativa entre IMC e os indicadores de glicemia e colesterol nesta base específica, reforçando a necessidade de análises mais aprofundadas em estudos futuros.

O projeto contribuiu significativamente para o desenvolvimento de competências em manipulação de dados, análise exploratória, visualização de informações e aplicação prática dos conceitos de Ciência de Dados.